Benchmark reproducible de circuitos cuánticos variacionales (VQC/VQN) para NLP bajo restricciones NISQ

Luis Daniel González Alcocer
Tecnológico de Monterrey
30 de octubre de 2026

2. Agenda

3. Contexto y pregunta de investigación
4. Diseño experimental
5. Arquitecturas evaluadas
6. Descriptores del circuito
7. Resultados: descriptores
8. Resultados: tarea IMDb y CoLA
9. Resultados: ruido
10. Hipótesis pre-registradas
11. Repositorio y reproducibilidad
12. Pendientes y conclusiones

3. Contexto y pregunta de investigación

Pregunta central

Qué propiedades de un circuito cuántico variacional (número de qubits, profundidad, codificación y estructura del ansatz) explican su desempeño, su entrenabilidad y su robustez al ruido cuando el circuito es el único componente que aprende.

Lo que este proyecto no es

No busca demostrar ventaja cuántica. Los modelos clásicos se reportan como referencia, no como competidores.

Lo que este proyecto es

Un benchmark reproducible de siete familias VQC publicadas, con hipótesis escritas antes de correr los experimentos.

4. Diseño experimental

Fase	Pregunta que responde	Estado
Descriptores	Qué tan expresivo, entrelazado y entrenable es cada circuito antes de entrenarlo (P1 a P6, G1 a G6).	**Completo**
fair-v1	Protocolo híbrido con capas clásicas grandes. Archivado: las capas clásicas hacían el trabajo.	**Completo**
pure-v1 IMDb	Desempeño cuando solo el circuito aprende. 7 familias, $n \in \{4, 6, 8\}$, $d \in \{1, 3, 5\}$, 10 semillas.	**Completo**
pure-v1 CoLA	Mismo protocolo en aceptabilidad gramatical.	**Parcial** ($n = 4$)
Ruido	Cómo cambia la predicción con ruido de hardware ($n = 4$).	**Completo**

4. Diseño experimental: reglas del protocolo pure-v1

Qué entra al circuito

Cada texto pasa por un modelo de lenguaje congelado (MiniLM) y luego por PCA. Ninguna capa clásica aprende. La salida es $p(y = 1) = \sigma(a\langle Z_0 \rangle + b)$: solo 2 números clásicos entrenables.

Cómo se entrena

Adam, 20 épocas, lote de 32. El 20% del entrenamiento se aparta como validación y elige la mejor época.

Cómo se decide

10 semillas pareadas por celda. Métrica principal: MCC en prueba. Diferencia mínima de interés (SESOI): 0.03 MCC. Corrección de Holm, $\alpha = 0.05$.

Pre-registro

Las 8 hipótesis y las reglas de decisión se congelaron en git (etiqueta `prereg-pure-v1`) antes de la primera corrida.

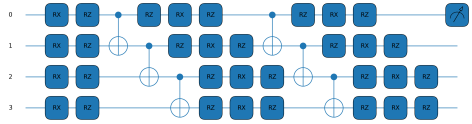
5. Arquitecturas evaluadas

Familia	Fuente	Codificación	Parámetros	DLA
A1 HEA	Kandala 2017	ángulo R_Y, PCA(n)	$n(3d+2)$	$\mathfrak{su}(2^n)$
A2 Strongly entangling	Schuld 2020	ángulo R_Y, PCA(n)	$3nd$	$\mathfrak{su}(2^n)$
A3 Re-uploading	Pérez-Salinas 2020	ángulo repetido en cada capa	$3nd$	$\mathfrak{su}(2^n)$
A4 DisCoCat (plantilla)	Meichanetzidis 2020	ángulo R_Y, PCA(n)	$n(d+1)$	$\mathfrak{su}(2^n)$
A5 Circuit-centric	Schuld 2020	amplitud, PCA(2^n)	$6nd+3$	$\mathfrak{su}(2^n)$
A6 IQP + VQC	Havlíček 2019	mapa ZZ de segundo orden	$2n(d+1)$	$\mathfrak{su}(2^n)$
A7 Farhi-Neven	Farhi 2018	qubit de lectura + $n-1$ datos	$2(n-1)d$	$3(n-1)$

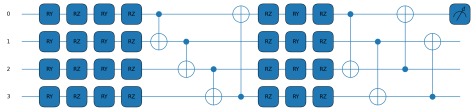
Por qué importa la columna DLA

El álgebra de Lie dinámica (DLA) mide cuántas direcciones puede explorar el circuito. Si crece como 4^n (A1 a A6), la teoría predice gradientes que se apagan al crecer n. A7 es la única familia con DLA pequeña: es el control del estudio.

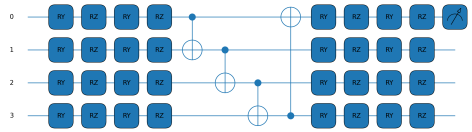
5. Circuitos A1 a A4 ($n = 4$)



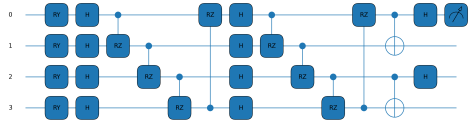
A1 HEA



A2 Strongly entangling



A3 Re-uploading

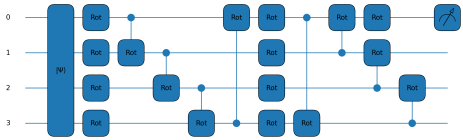


A4 DisCoCat (plantilla)

Lectura

Todas las familias leen $\langle Z_0 \rangle$ en el qubit 0. Los diagramas se generan desde el código (`figures/make_diagrams.py`), no a mano.

5. Circuitos A5 a A7


0
1
2
3
|Ψ⟩
Rot
Rot
Rot

6. Descriptores del circuito: qué mide cada uno

Tag	Qué mide, en palabras simples
P1	Expresividad: qué tanto cubre el circuito el espacio de estados (distancia KL a Haar).
P2	Entrelazamiento promedio que produce (Meyer-Wallach).
P3	Dimensión efectiva: cuántos parámetros realmente cambian el estado.
P4	Dimensión del álgebra de Lie dinámica (DLA).
P5, P6	Costo: número de parámetros y de compuertas de dos qubits.
G1	Varianza del gradiente al crecer n. Si decae como $e^{-\alpha n}$, hay *barren plateau*.
G3	Ancho n^* donde el gradiente cae por debajo de lo que 1024 shots pueden medir.
G4	Diferencia entre costo global y local.
G5	Gradiente bajo ruido despolarizante.
G6	Efecto de inicializar con ángulos pequeños.

7. Resultados: descriptores

	A1	A2	A3	A4	A5	A6	A7
G1: α global ($d = 5$)	0.69	0.69	0.69	0.73	0.68	0.68	0.44
G3: n^* (1024 shots)	8.7	8.3	8.4	7.8	8.8	8.6	no cruza
G6: rescate con ángulos pequeños	1.9×	5.6×	0.6×	14×	62×	0.3×	35×

Lo que se confirma

A1 a A6 pierden gradiente al ritmo que predice la teoría: $\alpha \approx \ln 2 = 0.693$. Con 1024 shots, el gradiente se vuelve inmedible cerca de 8 qubits.

La excepción

A7 (DLA pequeña) tiene una varianza de gradiente 22 a 38 veces mayor que A1, A2 y A4 a $n = 6$, $d = 5$, y no cruza el límite de shots en $n \leq 10$.

8. Resultados IMDb: mejor celda por familia (MCC en prueba)

Familia	n	d	MCC (IC 95%)	Ref. logreg	Semillas fallidas	Categoría
A1	8	5	0.273 ± 0.048	0.270	1 de 10	Desempeña
A2	8	5	0.262 ± 0.060	0.270	2 de 10	Limitado por capacidad
A4	8	5	0.252 ± 0.053	0.270	3 de 10	Limitado por entrenabilidad
A7	8	1	0.235 ± 0.052	0.275	4 de 10	Limitado por entrenabilidad
A3	6	5	0.220 ± 0.051	0.283	4 de 10	Limitado por entrenabilidad
A6	8	5	0.086 ± 0.045	0.270	10 de 10	Limitado por entrenabilidad
A5	8	1	0.070 ± 0.026	0.424	10 de 10	Limitado por entrenabilidad

Cómo leer la tabla

"Ref. logreg" es una regresión logística con las mismas entradas que ve el circuito. "Semilla fallida" significa MCC menor a 0.2. Referencias fuertes: MiniLM completo 0.47, TF-IDF 0.63.

8. Resultados IMDb: efecto del número de qubits ($d = 5$)

n	A1	A2	A3	A4	A5	A6	A7
4	0.145	0.194	0.157	0.147	0.030	0.085	0.077
6	0.255	0.257	0.220	0.246	0.042	0.042	0.182
8	0.273	0.262	0.220	0.252	-0.009	0.087	0.159

Patrón

Las familias de ángulo (A1 a A4) mejoran de 4 a 6 qubits y luego se aplanan. Siguen de cerca a la regresión logística con las mismas features: el límite lo pone la información que entra, no el circuito.

Las que no aprenden

A5 (amplitud) y A6 (IQP) quedan cerca de cero en todas las celdas, aunque A5 recibe más información (PCA de 2^n componentes).

8. Resultados: categorías y CoLA

IMDb, 69 celdas

Categoría	Celdas
Limitado por entrenabilidad	46
Piso (MCC no distinto de 0)	16
Limitado por capacidad	6
Desempeña	1

Lectura

El problema dominante es entrenar: con inicialización uniforme muchas semillas no despegan, sobre todo a $d = 1$.

CoLA (aceptabilidad gramatical)

A $n = 4$, las 27 celdas quedan en el piso: MCC entre -0.03 y $+0.03$. La regresión logística con las mismas features también da 0.00. El problema está en la representación (MiniLM + PCA a 4 componentes no conserva la señal sintáctica), antes del circuito.

Pendiente

CoLA a $n = 6$ y $n = 8$: 42 celdas sin correr.

9. Resultados: ruido de hardware ($n = 4$, IMDb)

Qué se hizo

Modelos entrenados sin ruido se evaluaron con ruido despolarizante, bit flip y phase flip, con tasa de dos qubits 10 veces la de un qubit. Nivel NISQ: 10^{-3} y 10^{-2}.

Resultado

En las 21 celdas, la pérdida de MCC está entre -0.011 y $+0.020$, debajo del SESOI de 0.03. A $n = 4$ ninguna familia queda limitada por ruido.

Qué predice la pérdida

El número de compuertas de dos qubits predice la pérdida mejor que la profundidad ($\rho = 0.81$ contra 0.68). Esto contradice la hipótesis H7.

10. Hipótesis pre-registradas: veredictos

ID	Predicción (simplificada) y lo que pasó	Veredicto
H1	El gradiente decae con n y el costo local decae mucho más lento. Se cumple en A1, A4, A5, A6; falla en A2, A3 y A7.	Refutada
H2	A $n = 6$ el gradiente cae con la profundidad y se estabiliza. Ninguna familia cae con d.	Refutada
H3	$d = 3$ mejora a $d = 1$, y $d = 5$ no agrega más. Solo A3 (y A4 a $n = 8$) mejora con significancia; el resto queda inconcluso.	Refutada
H4	$n = 6$ mejora a $n = 4$, y $n = 8$ no agrega más. Solo A7 mejora con significancia ($d = 1$ y $d = 3$).	Refutada
H5	(a) A1, A2, A4, A7 equivalentes: no se demuestra. (b) A7 con más gradiente: sí. (c) A1 a $d = 1$ con más fallas: sí.	Refutada (a)
H6	Re-upload y amplitud superan a ángulo; IQP no supera a ángulo. Amplitud queda peor; IQP se cumple.	Refutada
H7	La profundidad predice la pérdida por ruido mejor que las compuertas de dos qubits. Fue al revés.	Refutada
H8	El orden entre familias es más consistente que en fair-v1. Falta el cálculo de fair-v1.	Incompleta

Por qué tantas refutadas

Una hipótesis se marca refutada si cualquier parte falla. Muchas partes salen inconclusas con 10 semillas. Un resultado refutado también es un resultado: se reporta tal como se escribió antes de los datos.

10. Limitaciones declaradas

Diferencias con los artículos

A4 no post-selecciona las “cups” y no usa un parser. A5 a $n = 6$ tiene más compuertas controladas que la regla del artículo. A6 recibe ángulos en $[0, \pi]$, no en $(0, 2\pi]$. Todo está declarado en `docs/IMPLEMENTATION.md` y probado en `tests/test_conventions.py`.

Límites del diseño

El contraste A3 contra A2 cambia la codificación y el entrelazador a la vez. La inicialización uniforme favorece las fallas; G6 muestra que ángulos pequeños ayudarían a A4, A5 y A7. Todo es simulación exacta, no hardware.

11. Repositorio y reproducibilidad

```
vqc_scorecard/
  ansatze/    A1 a A7, un archivo cada una
  probes/     física: gradientes, DLA, QFIM
  metrics/    P1 a P6, G1 a G6
  tasks/      datos, modelo, protocolo
  noise/      modelos de ruido
  tests/      239 pruebas
  results/    JSON y JSONL de todo
  docs/       implementación, pre-registro
```

Reproducir

```
pip install -r requirements.txt
python -m vqc_scorecard.tests
python -m vqc_scorecard.tasks.pure_report
python -m vqc_scorecard.figures.export_pure_tables
```

Garantías

Versiones fijas (PennyLane 0.42.3, NumPy 2.4.4). Cada resultado lleva el digest del protocolo (`b2833a59e87d`). Las tablas de esta presentación salen de `results/pure/cells.csv`.

12. Pendientes para cerrar

Tarea	Qué falta	Estado
CoLA a $n = 6$ y $n = 8$	42 celdas de 10 semillas	**Pendiente**
H8	Coeficiente W de Kendall de fair-v1 a $n = 4$, $d = 3$	**Pendiente**
G5 para A5 a A7	Barrido de ruido en descriptores	**Pendiente**
Publicación del repositorio	GitHub, etiqueta de versión, DOI (Zenodo)	**Pendiente**

12. Conclusiones

- Seis de siete familias pierden gradiente al ritmo que predice la teoría ($\alpha \approx \ln 2$). La única excepción, A7, tiene una DLA pequeña y es simulable clásicamente.
- Cuando solo el circuito aprende, las familias de ángulo (A1 a A4) llegan al nivel de una regresión logística con las mismas features, y no lo superan.
- Amplitud (A5) e IQP (A6) no aprenden la tarea en este protocolo.
- El cuello de botella principal es entrenar, no el ruido: a $n = 4$ el ruido NISQ cambia el MCC menos de 0.03.
- En CoLA, la representación de entrada no tiene la señal; ningún circuito la puede recuperar.

Referencias

- Kandala, A. et al. (2017). Hardware-efficient variational quantum eigensolver for small molecules and quantum magnets. *Nature*, 549, 242.
- Schuld, M., Bocharov, A., Svore, K. M., Wiebe, N. (2020). Circuit-centric quantum classifiers. *Phys. Rev. A*, 101, 032308.
- Pérez-Salinas, A., Cervera-Lierta, A., Gil-Fuster, E., Latorre, J. I. (2020). Data re-uploading for a universal quantum classifier. *Quantum*, 4, 226.
- Meichanetzidis, K., Gogioso, S., de Felice, G., Chiappori, N., Toumi, A., Coecke, B. (2020). Quantum natural language processing on near-term quantum computers. arXiv:2005.04147.
- Havlíček, V. et al. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567, 209.
- Farhi, E., Neven, H. (2018). Classification with quantum neural networks on near term processors. arXiv:1802.06002.
- Ragone, M. et al. (2024). A Lie algebraic theory of barren plateaus for deep parameterized quantum circuits. *Nature Communications*, 15, 7172.
- Larocca, M. et al. (2025). Barren plateaus in variational quantum computing. *Nature Reviews Physics*, 7, 174.